

Dense MEC 환경에서 QECO-ADAPT의 부하 적응형 오프로딩 성능 분석

나현우* 이창우**

Load-Adaptive Offloading Performance Analysis of QECO-ADAPT in Dense MEC Environments

Hyeon Woo. Na* Chang Woo Lee**

요 약

모바일 엣지 컴퓨팅(MEC)의 연산 오프로딩은 QoE, 지연, 에너지, deadline 내 작업 완료를 동시에 고려해야 할 다목적 의사결정 과제이다. 본 연구는 기존 QECO에 부하 적응형 energy weight와 offloading gating을 더한 QECO-ADAPT를 중심으로, user=10, 30, 50, 80, edge=1, episode=400 조건에서 단일 edge dense 환경의 성능을 검토한다. 결과상 QECO-ADAPT는 낮은 부하에서는 QECO와 비교해 QoE와 dropped-task count 손실이 나타났으나, 사용자 밀도가 높아진 조건에서는 전체 episode 평균 기준 QoE, Delay, Energy, dropped-task count를 향상하였다. 구체적으로 user=30 이상에서 초기 수렴 손실을 낮추고, 후반 안정 구간에서는 QECO 성능에서 크게 이탈하지 않는 양상을 보였다. 그러므로 QECO-ADAPT는 QECO를 대신하기보다 dense MEC 환경에서 warm-up 손실을 줄이는 부하 적응형 보조 알고리즘으로 해석할 수 있다.

Abstract

In mobile edge computing (MEC), computation offloading is a multi-objective decision-making task that must jointly consider QoE, delay, energy consumption, and task completion within the deadline. This review focuses on QECO-ADAPT, which adds load-adaptive energy weighting and offloading gating to the existing QECO framework, and evaluates its performance in a single-edge dense environment under user=10, 30, 50, 80, edge=1, and episode=400 settings. The results show that QECO-ADAPT incurs QoE and dropped-task count losses compared with QECO under low-load conditions, but improves QoE, Delay, Energy, and dropped-task count in terms of the full-episode average as user density increases. Specifically, when the number of users is 30 or higher, QECO-ADAPT reduces early-stage convergence loss and follows QECO's performance closely in the final stable phase. Therefore, QECO-ADAPT can be interpreted not as a replacement for QECO, but as a load-adaptive auxiliary algorithm that reduces warm-up loss in dense MEC environments.

Key words

MEC, Offloading, QECO, QECO-ADAPT, dense MEC, energy-aware control, early convergence dropped-task count etc.

*국민대학교, nahw0861@kookmin.ac.kr, **국민대학교, leecw05@kookmin.ac.kr (교신저자)

※ 해당 프로젝트는 대학혁신 지원사업의 일환으로 진행된 프로젝트입니다.

I. 서 론

모바일 엣지 컴퓨팅(Mobile Edge Computing, MEC)에서 연산 오프로딩은 QoE, Delay, Energy, 그리고 deadline 내 작업 완료를 함께 고려해야 하는 다목적 의사결정 문제이다. 이용자 수가 늘고 edge server에 작업 요청이 몰리면 처리 delay와 dropped task가 증가할 수 있으므로[1], dense MEC 환경에서는 에너지 절감에만 집중된 정책은 충분하지 않다.

DROO는 wireless powered MEC에서 binary online offloading baseline을 제시했고[2] QECO는 task completion, delay, energy를 고려하는 D3QN/LSTM 기반 장기 QoE 최대화 알고리즘이다[3]. 또한 online offloading 연구들은 queue stability와 stochastic task arrival가 MEC 성능에 중요한 영향을 준다[4][5]. partial offloading 연구는 action 구성과 resource allocation 문제가 복잡해질 수 있음을 보여준다[6]. 따라서, 복합 무선 자원 관리 문제는 학습 기반 최적화는 효과적인 접근으로 활용할 수 있다[7].

이에 본 연구는 dense MEC 환경에서 QECO의 초기 warm-up 손실을 완화하기 위한 보완형 알고리즘인 QECO-ADAPT를 평가하고 QECO-ADAPT는 기존 QECO reward에 effective load 기반 energy weight와 offloading gating을 추가한다.

II. 실험 기준과 평가 방식

QECO 원문은 50 mobile devices (MDs)와 5 edge nodes (ENs)를 기본 환경으로 사용하므로, edge당 평균 사용자 밀도는 10 MDs/EN이다[3]. 본 분석은 이를 기준 밀도 $d_0 = 10$ 으로 두고 edge 수를 1로 고정한 뒤, 사용자 수를 증가시켰다. 따라서 각 조건은 원문 대비 1x, 3x, 5x, 8x dense stress condition으로 해석된다.

주요 분석 지표는 전체 episode 평균이다. 또한 QECO-ADAPT의 목적은 최종 안정 구간에서 QECO를 개선하는 것이 아니라, 초반 warm-up 구간에 쌓이는 QoE 손실과 dropped-task를 줄이는 데 있다. Dropped tasks는 drop probability가 아니라 episode별 deadline 내 미완료 task이다.

III. QECO-ADAPT의 부하 적응형 제어 구조

QECO-ADAPT는 사용자 수, 시간대별 task arrival profile, 사용자 활동성, edge 수를 이용해 edge 하나가 처리해야 하는 effective load를 산정한다[4]. 사용자 집합을 $\mathbf{U} = 1, \dots, N$, edge node 집합을 $\mathbf{E} = 1, \dots, M$, 시간대별 task 생성 profile을 $\mathbf{b} = (b_1, \dots, b_K)$, 사용자별 활동성 계수를 $a_u \in [a_{\min}, a_{\max}]$ 로 둔다. 사용자 u 가 시간 t 에 task를 생성할 확률은 아래 식과 같다.

$$p_{arrive}(u, t) = \min(1, \max(0, b_{k(t)} a_u)) \quad (1)$$

평균 profile과 평균 사용자 활동성을 이용해 edge 하나가 평균 처리하는 task pressure를 정의한다.

$$\bar{b} = \frac{1}{K} \sum_{k=1}^K b_k \quad \bar{a} = \frac{1}{N} \sum_{u=1}^N a_u \quad L_{eff} = \frac{N \bar{b} \bar{a}}{M} \quad (2)$$

L_{eff} 는 사용자 수가 늘면 증가하고, edge 수가 늘면 감소한다. $M = 1$ 인 경우 사용자 수 증가는 곧 단일 edge dense stress 증가한다. QECO-ADAPT는 유효 부하를 adaptive gating과 energy weight에 적용한다[5]. edge당 부하 scale constant를 λ 라고 하면, gating strength는 다음과 같다.

$$g(L_{eff}) = \frac{L_{eff}}{L_{eff} + M\lambda} \quad (2)$$

$g(L_{eff})$ 는 load가 높아질수록 증가하며, 높은 부하에서 energy-aware behavior를 강화하는 계수로 활용된다. Adaptive energy weight는 다음과 같다.

$$w_E = w_0 (1 + g(L_{eff}))^\rho \quad (3)$$

위 식에서 $w_0 = 1.20$, $\rho = 0.35$, $\lambda = 10$ 을 사용한다. $\rho < 1$ 은 부하 증가에 따른 energy weight 상승을 완화해 QoE와 Drop의 급격한 저하를 줄인다.

이 weight는 QECO reward의 energy cost 항에 들어간다. task i 의 scaled energy를 E_i^{sc} , delay를 D_i , 단말 energy state를 s_i , 최대 허용 delay를 $D_{\max}$ 라면 비용 항과 reward는 아래와 같다.

$$C_i^{adapt} = 2(s_i D_i + (1 - s_i) w_E E_i^{sc}) \quad (4)$$

$$r_{done} = \alpha D_{\max}, \quad \alpha = 4$$

$$r_i^{adapt} = \begin{cases} -C_i^{adapt}, & \text{if unfinished} \\ r_{done} - C_i^{adapt}, & \text{otherwise} \end{cases}$$

여기서 unfinished task는 deadline 내 끝나지 않은 task이다. $\alpha = 4$ 는 이론적 계수라기보다 기존 QECO 공개 구현의 completion reward scale을 공통 평가에서 보존한 calibration parameter로 해석한다. 본 설정에서는 $D_{\max} = 10$ 이므로 $r_{done} = 40$ 이다. QECO-ADAPT는 completion reward scale은 유지하고, 부하에 따라 energy cost 항과 gating만 조절한다.

기존 QECO reward에 대한 policy-invariant reward shaping이 아니다. 부하가 증가할수록 delay와 energy 사이의 상대 가중치가 달라지므로[6], QECO-ADAPT의 정책은 기존 QoE를 최적화한 방식보다 dense 환경의 energy pressure와 dropped-task 누적을 낮추도록 다시 설계한 surrogate reward에 대한 정책이다.

학습 절차는 기존 QECO의 Dueling Double DQN과 LSTM 기반 load history 입력을 따르며[3], 즉시 보상 항에 기존 reward 대신 r_i^{adapt} 가 포함된다.

IV. 평균 성능 개선과 warm-up 손실 완화

다음 표는 전체 episode 평균 기준으로 QECO 대비 QECO-ADAPT의 변화량을 요약한 것이다. QoE는 증가가 이득이며, Delay, Energy, Dropped tasks, Runtime은 감소가 개선이다[1][2].

1x 조건에서는 QECO-ADAPT가 Energy를 줄였지만 QoE, Delay, Dropped tasks 측면에서는 손실을 보았다. 이는 원문 QECO의 기준 edge당 밀도 10 MDs/EN에서 기존 QoE 정책이 더 알맞다는 의미이다.

표 1. 실험 데이터 세트
Table 1. Experimental data sets

Users	Density	QoE	Delay	Energy	Dropped tasks	Runtime
10	1x	-2.142 (-9.13%)	+0.235 (-3.65%)	-1.039 (+7.83%)	+13.065 (-32.85%)	+0.080 (-5.07%)
30	3x	+1.251 (-10.97%)	-0.104 (+1.30%)	-2.142 (+5.37%)	-21.300 (+5.88%)	-0.137 (+3.12%)
50	5x	+2.689 (+41.45%)	-0.157 (+1.87%)	-2.435 (+12.25%)	-2.142 (+10.25%)	+0.712 (-10.98%)
80	8x	+3.337 (+89.51%)	-0.147 (+1.72%)	-2.142 (+18.29%)	-154.880 (+11.17%)	+1.031 (-10.83%)

반면 3x부터는 QoE, Delay, Energy, Dropped tasks가 함께 개선되어, QECO-ADAPT가 초반 수렴 구간 의 누적 손실을 줄이는 방향으로 작동함을 나타낸다.




그림 1. 3x density 조건의 전체 episode 평균 비교.
Fig. 1. Full-Episode Average Comparison under 3x Density

5x와 8x 조건에서는 QoE 개선 폭과 Energy 절감 폭이 더 커졌다. user=50, edge=1은 QoE 41.45% 증가, Energy 12.25% 감소, Dropped tasks 10.25% 감소가 함께 나타나는 대표 구간이다.

user=80, edge=1에서는 QoE를 89.51% 높이고, Energy를 18.29% 줄였으며, Dropped tasks도 11.17% 개선하였다. 다만 5x와 8x에서는 Runtime이 약 10% 내외로 증가하므로, 성능 향상과 계산 비용 증가의 trade-off를 함께 검토해야 한다.




그림 2. 5x density 조건의 전체 episode 평균 비교.
Fig. 2. Full-Episode Average Comparison under 5x Density




그림 3. 8x density 조건의 전체 episode 평균 비교.
Fig. 3. Full-Episode Average Comparison under 8x Density

8x 조건에서는 전체 평균과 함께 smoothed time-series를 같이 보는 것이 중요하다. 본 실험에서 QECO-ADAPT는 Delay 기준 약 195 episode 이후, QoE 기준 약 272 episode 이후, Dropped tasks 기준 약 265 episode 이후에 DROO보다 우세한 smoothed 성능을 보였다. 다만, Energy는 DROO가 전 구간에서 더 낮다. 이 결과는 에너지 단독 우세가 아니라 QoE-Delay-Drop 관점의 수렴 지향 우세로 해석된다.

V. 평균 성능 이득과 수렴 특성 분석

전체 episode 평균에서는 QECO-ADAPT의 이득이 크게 나타나지만, episode가 진행될수록 기준 알고리즘과 수렴한다. 그림 3, 4를 예로, 평균 기준으로 모든 주요 지표가 개선되지만, 후반 안정 구간은 QECO와 거의 같은 수준으로 수렴한다. 따라서 QECO-ADAPT의 핵심 가치는 성능을 급격히 높이는 데보다 초반 warm-up 손실을 줄이는 데 있다.




그림 4. 8x density 조건의 episode별 smoothed 성능 수렴 추이

Fig. 4. Episode-Wise Smoothed Performance Convergence Trend under 8x Density

VI. 결 론

본 연구는 QECO 원문의 사용자 밀도 10 MDs/EN을 기준으로 한 단일 엣지 고밀도 환경에서 QECO-ADAPT의 부하 적응 성능을 분석한 결과, 저 부하에서는 QoE와 dropped-task 측면에서 불리했으나 사용자 밀도가 3배 이상 증가한 환경에서는 QoE·지연·에너지·dropped tasks를 모두 개선하며 dense MEC 환경에서 QECO를 보완하는 방식으로 확인되었다. 본 연구는 기존 QECO의 학습 구조와 action space를 유지한 상태에서 부하 조건에 따라 reward와 offloading gating을 조절하여 초기 수렴 손실을 감소시키는 효과가 있다. 본 연구를 기반으로 향후에는 다중 seed와 직접적인 수렴 평가 지표를 활용해 warm-up 손실 감소 효과를 추가 검증하는 방향으로 연구하고자 한다.

참 고 문 헌

- [1] M. Tang and V. W. Wong, "Deep Reinforcement Learning for Task Offloading in Mobile Edge Computing Systems," *IEEE Transactions on Mobile Computing*, vol. 21, no. 6, pp. 1985-1997, Jun. 2022, doi: 10.1109/TMC.2020.3036871.
- [2] L. Huang, S. Bi, and Y.-J. Angela Zhang, "Deep Reinforcement Learning for Online Computation Offloading in Wireless Powered Mobile-Edge Computing Networks," *IEEE Transactions on Mobile Computing*, vol. 19, no. 11, pp. 2581-2593, Nov. 2020, doi: 10.1109/TMC.2019.2928811.
- [3] I. Rahmaty, H. Shah-Mansouri, and A. Movaghar, "QECO: A QoE-Oriented Computation Offloading Algorithm Based on Deep Reinforcement Learning for Mobile Edge Computing," *IEEE Transactions on Network Science and Engineering*, vol. 12, no. 4, pp. 3118-3130, 2025, doi: 10.1109/TNSE.2025.3556809.
- [4] S. Bi, L. Huang, H. Wang, and Y.-J. A. Zhang, "Lyapunov-Guided Deep Reinforcement Learning for Stable Online Computation Offloading in Mobile-Edge Computing Networks," *IEEE Transactions on Wireless Communications*, vol. 20, no. 11, pp. 7519-7537, 2021, doi: 10.1109/TWC.2021.3085319.
- [5] S. Chen and W. Jiang, "Online dynamic multi-user computation offloading and resource allocation for HAP-assisted MEC: an energy efficient approach," *Journal of Cloud Computing*, vol. 13, article 92, 2024, doi: 10.1186/s13677-024-00645-5.
- [6] L. Sun, R. Liang, L. Wan, K. Liu, Z. Ning, and J. Wang, "Online Partial Computation Offloading Optimization in Wireless Powered Mobile Edge Computing Network," *IEEE Transactions on Cognitive Communications and Networking*, vol. 12, pp. 1481-1495, 2026, doi: 10.1109/TCCN.2025.3612741.
- [7] H. Sun, X. Chen, Q. Shi, M. Hong, X. Fu, and N. D. Sidiropoulos, "Learning to optimize: Training deep neural networks for wireless resource management," in *Proc. IEEE SPAWC*, 2017, pp. 1-6, doi: 10.1109/SPAWC.2017.8227766.