

Dense MEC 환경에서 QECO-ADAPT 성능

Load-Adaptive Offloading Performance Analysis in
Dense MEC Environments

고밀도 사용자 환경에서 초기 수렴 손실을 완화하는 부하 적응형 알고리즘의
성능 평가

국민대학교 소프트웨어융합대학 인공지능 학부생 나현우
국민대학교 소프트웨어융합대학 지도교수 이창우

목차

01 연구 배경 및 동기

- MEC 환경의 다목적 의사결정 과제
- Dense 환경에서의 성능 저하 문제
- 기존 QECO의 한계점

02 관련 연구

- DROO: Binary online offloading baseline
- QECO: D3QN/LSTM 기반 QoE 최대화
- Queue stability 및 stochastic task arrival

03 실험 설계 및 환경 설정

- User density: 1x, 3x, 5x, 8x 조건
- Single edge (edge=1) 고정
- Episode=400 기준 평가

04 평가 지표

- QoE, Delay, Energy, Dropped-task count
- 전체 episode 평균 분석
- 초기 warm-up 손실 측정

05 QECO-ADAPT 알고리즘

- Load-adaptive energy weight
- Offloading gating 메커니즘
- Reward function 구조

06 실험 결과 및 결론

- 밀도별 성능 비교 (1x~8x)
- 수렴 특성 분석
- 향후 연구 방향

연구 배경 및 동기



MEC 환경의 다목적 의사결정 과제

- QoE, Delay, Energy, deadline 내 작업 완료를 동시에 고려
- 이용자 수 증가 시 처리 지연 및 dropped task 증가



Dense 환경에서의 성능 저하 문제

- Edge server에 작업 요청 집중 시 성능 저하
- 기존 QECO의 QoE 정책만으로는 불충분



기존 QECO의 한계점

- 고밀도 사용자 환경에서 초기 수렴 손실 발생
- Warm-up 구간의 QoE 및 dropped-task 누적 문제

관련 연구

Deep Reinforcement Learning for Online Computation Offloading in Wireless Powered Mobile-Edge Computing Networks

Liang Huang[✉], *Member, IEEE*, Suzhi Bi[✉], *Senior Member, IEEE*, and Ying-Jun Angela Zhang[✉], *Senior Member, IEEE*

Abstract—Wireless powered mobile-edge computing (MEC) has recently emerged as a promising paradigm to enhance the data processing capability of low-power networks, such as wireless sensor networks and internet of things (IoT). In this paper, we consider a wireless powered MEC network that adopts a binary offloading policy, so that each computation task of wireless devices (WDs) is either executed locally or fully offloaded to an MEC server. Our goal is to acquire an online algorithm that optimally adapts task offloading decisions and wireless resource allocations to the time-varying wireless channel conditions. This requires quickly solving hard combinatorial optimization problems within the channel coherence time, which is hardly achievable with conventional numerical optimization methods. To tackle this problem, we propose a Deep Reinforcement learning-based Online Offloading (DROO) framework that implements a deep neural network as a scalable solution that learns the binary offloading decisions from the experience. It eliminates the need of solving combinatorial optimization problems, and thus greatly reduces the computational complexity especially in large-size networks. To further reduce the complexity, we propose an adaptive procedure that automatically adjusts the parameters of the DROO algorithm on the fly. Numerical results show that the proposed algorithm can achieve near-optimal performance while significantly decreases the computation time by more than an order of magnitude compared with existing optimization methods. For

DROO

- Wireless powered MEC에서 binary online offloading 제시
- 기본 baseline 알고리즘으로 활용
- 에너지 효율 중심 접근

QECO: A QoE-Oriented Co-Offloading Algorithm Based on Deep Reinforcement Learning for Mobile I

Iman Rahmaty[✉], Hamed Shah-Mansouri[✉], *Member, IEEE*,

QECO

- D3QN/LSTM 기반 장기 QoE 최대화 알고리즘
- Task completion, delay, energy 통합 고려
- 50 MDs, 5 ENs 환경 기준 설계

Lyapunov-Guided Deep Reinforcement Learning for Stable Online Computation Offloading in Wireless Powered Mobile-Edge Computing Networks

Online dynamic multi-user computation offloading and resource allocation for HAP-assisted MEC: an energy efficient approach

Queue Stability 연구

- Queue stability와 stochastic task arrival이 MEC 성능에 중요
- Partial offloading 및 resource allocation 복잡도 증가
- 학습 기반 최적화 접근 필요성

실험 설계 및 환경 설정



User Density 조건

- 1x (10 MDs), 3x (30 MDs), 5x (50 MDs), 8x (80 MDs)
- 원문 대비 1x, 3x, 5x, 8x dense stress condition



Edge 환경 고정

- Single edge (edge=1) 고정 설정
- Edge 당 평균 사용자 밀도 증가 조건 평가



평가 기준

- Episode=400 기준으로 전체 평균 성능 측정
 - 초기 warm-up 구간과 후반 안정 구간 비교 분석
-

평가 및 분석 지표

QoE, Delay, Energy, Dropped-task

- QoE: 사용자 체감 품질 (증가가 이득)
- Delay: 작업 처리 지연 시간 (감소가 개선)
- Energy: 에너지 소비량 (감소가 개선)
- Dropped-task count: 미완료 작업 수 (감소가 개선)

전체 Episode 평균 분석

- 전체(400 episodes) 평균 기준 성능 비교
- QECO 대비 QECO-ADAPT의 변화량 측정
- 밀도별 개선율 정량 평가

초기 Warm-up 손실 측정

- 초반 수렴 구간의 누적 손실 평가
- Episode별 smoothed time-series 분석
- 안정 구간 도달 시점 비교

Trade-off 분석

- 성능 향상 vs 계산 비용 (Runtime) 증가
- 5x, 8x 조건에서 약 10% Runtime 증가
- 실용성 및 효율성 종합 검토

QECO-ADAPT 알고리즘 구조

Offloading Gating 메커니즘

- 유효 부하 기반 gating strength 계산
- 높은 부하에서 energy-aware behavior 강화
- Scale constant를 활용한 적응형 제어
- Task offloading 결정에 직접 반영

Load-adaptive Energy Weight

- 부하 증가에 따라 energy weight를 동적으로 조정
- QoE와 Drop 급격한 저하 완화
- Reward function 내 energy cost 항에 적용
- 부하 기반 가중치로 dense 환경 대응

기존 QECO 기반 확장

- D3QN/LSTM 기반 학습 구조 유지
- Action space와 즉시 보상 항 조절
- Load-adaptive reward/cost reweighting 적용
- 기존 QECO의 completion reward scale 보존

Effective Load 산정 방식




사용자 수 및 Task Arrival Profile 반영

- 사용자 집합, edge node 집합, 시간대별 task 생성 profile 활용
- 사용자별 활동성 계수를 통해 task 생성 확률 산정



Edge 당 평균 Task Pressure 계산

- 평균 profile과 사용자 활동성으로 edge 하나가 처리하는 task pressure 정의
- 사용자 수 증가 시 pressure 증가, edge 수 증가 시 감소



부하 증가에 따른 적응형 제어

- 유효 부하를 adaptive gating과 energy weight에 적용
- Dense stress 조건에서 부하 기반 동적 조절 수행

$$\mathbf{b} = (b_1, \dots, b_K)$$
$$a_u \in [a_{\min}, a_{\max}]$$

$$\bar{b} = \frac{1}{K} \sum_{k=1}^K b_k \quad \bar{a} = \frac{1}{N} \sum_{u=1}^N a_u$$

$$L_{eff} = \frac{N \bar{b} \bar{a}}{M}$$

Gating Strength 설계

$$g(L_{eff}) = \frac{L_{eff}}{L_{eff} + M\lambda}$$

부하 증가 시 Energy-aware Behavior 강화

- Edge 당 부하를 scale constant로 나눈 gating strength 정의
- Load가 높아질수록 gating strength 증가
- 높은 부하에서 energy-aware behavior를 강화하는 계수로 활용
- QECO-ADAPT의 핵심 적응형 메커니즘

Scale Constant 기반 조절 및 High-load 환경 대응

- Gating strength는 reward function의 조절 계수로 작용
- Dense MEC 환경에서 energy cost 항 가중치 증가
- High-load 조건에서 QoE와 dropped task 균형 유지
- 부하 변화에 따른 실시간 정책 조정 가능

Adaptive Energy Weight

$$w_E = w_0 (1 + g(L_{eff}))^\rho$$

부하 기반 동적 가중치

- 유효 부하에 따라 energy weight 동적 조정
- 부하 증가 시 energy 비용 상승 완화
- w_0, ρ : energy weight의 증가 곡률 제어
- Dense 환경에서 균형잡힌 의사결정 지원

QoE 및 Drop 저하 완화

- Energy weight 상승으로 QoE 급격한 저하 방지
- Dropped task count 증가 억제
- 부하 변화에 따른 점진적 조정
- 초기 warm-up 구간 손실 감소 효과

Reward Function 적용

- QECO의 reward function에 adaptive weight 통합
- Scaled energy와 delay 비용 항에 적용
- Completion reward scale은 유지
- Policy-invariant shaping이 아닌 energy cost 재가중

Reward Function 구조

$$C_i^{adapt} = 2(s_i D_i + (1 - s_i) w_E E_i^{sc})$$
$$r_{done} = \alpha D_{\max}, \quad \alpha = 4$$
$$r_i^{adapt} = \begin{cases} -C_i^{adapt}, & \text{if } unfinished \\ r_{done} - C_i^{adapt}, & \text{otherwise} \end{cases}$$

Completion Reward Scale 유지

- 기존 QECO의 completion reward scale 보존
- Task 완료 보상 체계는 동일하게 유지하여 정책 일관성 확보

Energy Cost 및 Gating 조절

- Adaptive energy weight와 gating strength를 energy cost 항에 적용
- 부하에 따라 energy와 delay 사이의 상대 가중치 동적 조정

Load-Adaptive Reward Reweighting

- Dense 환경의 energy pressure와 dropped-task 누적 감소 목표
- Surrogate reward에 대한 정책으로 재설계된 구조

1x Density 조건 결과



Energy 개선

- 저부하 환경에서 에너지 효율성 향상
- QoE 9.13% 감소







QoE 및 Delay 손실

- Delay 3.65% 증가 | Dropped tasks 32.85% 증가
- 사용자 경험 측면에서 불리



기존 QECO 우세

- 기준 밀도 조건, 기존 QECO 정책이 더 적합
- Dense 환경 특화 알고리즘임을 확인



3x Density 조건 결과



QoE 개선

- QoE 10.97% 증가
- 초기 수렴 구간에서 손실 완화 효과 확인







Delay 개선

- Delay 1.30% 감소
- 부하 증가 환경에서 지연 시간 안정화



Dropped Tasks 개선

- Dropped tasks 5.88% 개선
- Energy 5.37% 절감으로 효율성 향상



5x Density 조건 결과



QoE 개선

- QoE 41.5% 증가
- 안정적인 성능 수렴







Energy 효율 개선

- Energy 12.25% 감소
- 부하 적응형 제어의 효과 확인



Dropped Tasks 개선

- Dropped tasks 10.25% 개선
- Deadline 내 작업 완료율 향상



8x Density 조건 결과



QoE 개선

- QoE 89.51% 증가
- 초고밀도 환경에서 QECO-ADAPT의 이점







Energy 효율 개선

- Energy 18.29% 감소
- 부하 적응형 제어의 효과 확인



Dropped Tasks 개선

- Dropped tasks 11.17% 개선
- Runtime 10.83% 증가는 성능 향상 대비 수용 가능



Runtime 비교 분석

계산 비용 증가

- 고밀도 3x-8x에서 약 9-11% 증가
- 부하 적응형 제어 연산 추가로 인한 오버헤드
- 고밀도 환경에서 불가피한 비용
- 전체 시스템 효율성 관점 필요


성능-비용 Trade-off

- 성능 향상 폭이 비용 증가 상회
- QoE 89.51% vs Runtime 10.83%
- 사용자 경험 개선 효과 우선
- 실시간 처리 요구사항 검토 필요

실용성 평가


- Dense MEC 환경에서 실용적
- 초기 수렴 손실 감소 가치 높음
- 장기 운영 시 효율성 확보
- 적용 환경별 맞춤 평가 권장

Average QoE



← 8x Averagy

Trimmed Median Episode Runtime



8x Runtime →

Smoothed Time-Series 분석



Delay 수렴 시점

- 8x 조건에서 195 episode 이후 DROO 대비 우세
- 초기 구간 손실 완화 효과 명확







QoE 수렴 시점

- 272 episode 이후 안정적 우세 확보
- 장기 학습 효과로 품질 지속 개선



Dropped Tasks 수렴 시점

- 265 episode 이후 우수한 성능 유지
- QoE-Delay-Drop 관점 종합 수렴 달성



수렴 특성 분석



초반 Warm-up 효과

- 초기 episode에서 손실 감소 효과 확인
- Dense 환경 초기 안정화 기여







후반 안정 구간

- 후반부에서 QECO와 유사한 성능
- 장기 운영 신뢰성



종합 수렴 평가

- Energy 단독 우세 아닌 종합 최적화
- QECO 보완 알고리즘으로 기능



핵심 발견사항




저부하 환경 (1x Density)

- QECO가 QoE 9.13% 우세 | Energy 7.83% 개선
- 기존 QECO가 적합



고밀도 환경 (3x 이상)

- QoE · Delay · Energy · Dropped 개선
- 5x: QoE +41.45%, Energy -12.25% | 8x: QoE +89.51%, Dropped Tasks -11.17%



QECO-ADAPT의 핵심 가치

- 초기 warm-up 손실 완화가 목표, 후반은 QECO와 유사 수렴
- Dense MEC 보조 알고리즘

결론

Warm-up 손실 감소

- 초기 수렴 구간 손실 완화
- Episode 평균 성능 개선
- QoE, Delay, Energy 동시 향상
- Dropped-task count 감소
- 3x 이상 밀도에서 효과 검증

보완형 알고리즘

- QECO를 대체하는 것이 아닌 보완
- Dense MEC 환경에서 효과적
- 저부하에서는 기존 QECO 유지
- 고밀도 환경에서 선택적 활용
- Load-adaptive 메커니즘 적용

부하 적응형 제어

- Energy weight 동적 조정
- Offloading gating 메커니즘
- Effective load 기반 적응
- 부하 증가 시 자동 대응
- Load-adaptive energy/cost reweighting

향후 연구 방향



다중 Seed 기반 추가 검증

다양한 random seed 실험 | 통계적 유의성 강화 | Warm-up 손실 감소 재확인



직접적인 수렴 평가 지표

Episode별 수렴 속도 측정 | 안정성 지표 개발·적용 | QoE-Delay-Drop 통합 메트릭 설계



Multi-edge 환경 확장

Edge node 증가 시나리오 | 분산 환경 성능 평가 | 실제 네트워크 적용 연구